

# 第三章 迭代法

## 3.4 解线性方程组的迭代法

# 求解线性方程组的迭代法

## 直接法的缺点：

- ✓ 运算量大，不适合大规模的线性方程组求解；
- ✓ 对于一些大型稀疏矩阵，浪费内存严重。

**迭代法：** 从一个初始向量出发，按照一定的迭代格式，构造出一个趋向于真解的无穷序列。

- ✓ 只需存储系数矩阵中的非零元素；
- ✓ 运算量不超过  $O(kn^2)$ ，其中  $k$  为迭代步数。

迭代解法是目前求解大规模线性方程组的主要方法。



# 解线性方程组迭代法的基本思想

迭代格式的建立:

$$\begin{array}{ccc} Ax = b & \longleftrightarrow & Mx = Nx + b \\ & A = M - N & \updownarrow \\ & & x = M^{-1}Nx + M^{-1}b \end{array}$$

给定一个初始向量  $x^{(0)}$ , 令  $G = M^{-1}N$ ,  $f = M^{-1}b$ , 可得  $x = Gx + f$ , 其迭代格式为  $x^{(k+1)} = Gx^{(k)} + f$ 。其中  $G$  称为迭代矩阵。  $x^{(k)} = (x_1^{(k)}, x_2^{(k)}, \dots, x_n^{(k)})^T, k = 0, 1, 2, \dots$

若产生的迭代序列  $\{x^{(k)}\}$  收敛到一个确定的向量  $x^*$ , 则  $x^*$  就是原方程组的解。

# 1. Jacobi 迭代

令  $A = D + L + U$ , 其中  $D = \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$ ,

$$L = \begin{bmatrix} 0 & & & \\ a_{21} & 0 & & \\ \vdots & \ddots & \ddots & \\ a_{n1} & \cdots & a_{n,n-1} & 0 \end{bmatrix}, \quad U = \begin{bmatrix} 0 & a_{12} & \cdots & a_{1n} \\ & 0 & \ddots & \vdots \\ & & \ddots & a_{n-1,n} \\ & & & 0 \end{bmatrix}$$

$$(D + L + U)x = b, \Rightarrow Dx = b - (L + U)x$$

若  $D$  可逆, 则  $x = -D^{-1}(L + U)x + D^{-1}b$

令  $G = -D^{-1}(L + U) = I - D^{-1}A$ ,  $f = D^{-1}b$ , 有  $x = Gx + f$

则可得雅可比 (Jacobi) 迭代格式:  $x^{(k+1)} = Gx^{(k)} + f$ ,

$k = 0, 1, 2, \dots$ ,  $G$  称为雅可比 (Jacobi) 迭代矩阵。

## Jacobi 迭代的分量形式:

$$\left\{ \begin{aligned} x_1^{(k+1)} &= \left( b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \dots - a_{1n}x_n^{(k)} \right) / a_{11} \\ x_2^{(k+1)} &= \left( b_2 - a_{21}x_1^{(k)} - a_{23}x_3^{(k)} - \dots - a_{2n}x_n^{(k)} \right) / a_{22} \\ &\dots\dots\dots \\ x_j^{(k+1)} &= \left( b_j - a_{j1}x_1^{(k)} \dots - a_{j,j-1}x_{j-1}^{(k)} - a_{j,j+1}x_{j+1}^{(k)} \dots - a_{jn}x_n^{(k)} \right) / a_{jj} \\ &\dots\dots\dots \\ x_n^{(k+1)} &= \left( b_n - a_{n1}x_1^{(k)} - a_{n2}x_2^{(k)} - \dots - a_{n,n-1}x_{n-1}^{(k)} \right) / a_{nn} \end{aligned} \right.$$

或：

$$x_i^{(k)} = \left[ b_i - \sum_{j=1, j \neq i}^n a_{ij} x_j^{(k-1)} \right] / a_{ii}, i = 1, 2, \dots, n,$$

## 迭代结束条件一般用:

$$\|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\| \leq \varepsilon, \varepsilon \text{ 为精度要求, } \|\cdot\| \text{ 为某种向量范数 (常用}\infty\text{-范数)}$$

### 例题3.7 用雅克比迭代解线性方程组:

$$\begin{cases} 10x_1 - x_2 - 2x_3 = 7.2 \\ -x_1 + 10x_2 - 2x_3 = 8.3 \\ -x_1 - x_2 + 5x_3 = 4.2 \end{cases}$$

初值取 $x_1^{(0)}=x_2^{(0)}=x_3^{(0)}=1$ , 精度要求 $\varepsilon=10^{-3}$ .

解: Jacobi 迭代的分量形式:

$$\begin{cases} x_1^{(k+1)} = \frac{(7.2 + x_2^{(k)} + 2x_3^{(k)})}{10} \\ x_2^{(k+1)} = \frac{(8.3 + x_1^{(k)} + 2x_3^{(k)})}{10} \\ x_3^{(k+1)} = \frac{(4.2 + x_1^{(k)} + x_2^{(k)})}{5} \end{cases}$$



例题3.7,  
改进

$$\left\{ \begin{array}{l} x_1^{(k+1)} = \frac{(7.2 + x_2^{(k)} + 2x_3^{(k)})}{10} \\ x_2^{(k+1)} = \frac{(8.3 + x_1^{(k+1)} + 2x_3^{(k)})}{10} \\ x_3^{(k+1)} = \frac{(4.2 + x_1^{(k+1)} + x_2^{(k+1)})}{5} \end{array} \right.$$

<b>k</b>	$x_1^{(k)}$	$x_2^{(k)}$	$x_3^{(k)}$	$\ \mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\ _\infty$
0	1	1	1	
1	1.0200	1.1320	1.2704	0.2704
2	1.08728	1.1928	1.2960	0.0673
3	1.09848	1.1990	1.2995	0.0112
4	1.0998	1.19988	1.2999	0.0013
5	1.1000	1.2000	1.3000	0.0002



## 2. Gauss-Seidel 迭代

写成矩阵形式:

$$\begin{pmatrix} x_1^{(k+1)} \\ x_2^{(k+1)} \\ \vdots \\ x_n^{(k+1)} \end{pmatrix} = \begin{pmatrix} 1/a_{11} & & & \\ & 1/a_{22} & & \\ & & \ddots & \\ & & & 1/a_{nn} \end{pmatrix} \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix} - \begin{pmatrix} 0 & & & \\ a_{21} & 0 & & \\ \vdots & \vdots & \ddots & \\ a_{n1} & a_{n2} & \cdots & 0 \end{pmatrix} \begin{pmatrix} x_1^{(k+1)} \\ x_2^{(k+1)} \\ \vdots \\ x_n^{(k+1)} \end{pmatrix} - \begin{pmatrix} 0 & a_{12} & \cdots & a_{1n} \\ & 0 & \cdots & a_{2n} \\ & & \ddots & \vdots \\ & & & 0 \end{pmatrix} \begin{pmatrix} x_1^{(k)} \\ x_2^{(k)} \\ \vdots \\ x_n^{(k)} \end{pmatrix}$$

$$\text{即 } \mathbf{x}^{(k+1)} = \mathbf{D}^{-1} (\mathbf{b} - \mathbf{L}\mathbf{x}^{(k+1)} - \mathbf{U}\mathbf{x}^{(k)})$$

$$\text{解得 } \boxed{\mathbf{x}^{(k+1)} = -(\mathbf{L} + \mathbf{D})^{-1} \mathbf{U}\mathbf{x}^{(k)} + (\mathbf{L} + \mathbf{D})^{-1} \mathbf{b}} \quad k = 0, 1, 2, \dots$$

此迭代格式称为高斯-塞德尔 (Gauss-Seidel) 迭代

$\mathbf{G} = -(\mathbf{L} + \mathbf{D})^{-1} \mathbf{U}$  称为 G-S 迭代矩阵

$$x_i^{(k)} = \frac{1}{a_{ii}} \left[ b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k)} - \sum_{j=i+1}^n a_{ij} x_j^{(k-1)} \right], i = 1, 2, \dots, n, \quad \text{程序3.3 P62}$$

### 3. 迭代的收敛性

**定理3.4** 设迭代矩阵 $G$ 的某种范数 $\|G\|<1$ ，则 $x=Gx+f$  存在唯一解，且对任意初值 $x^{(0)}$ ，迭代序列

$$x^{(k)} = Gx^{(k-1)} + f$$

收敛于 $x^*$ ，进一步有误差估计式

$$\|x^{(k)} - x^*\| \leq \frac{\|G\|}{1 - \|G\|} \|x^{(k)} - x^{(k-1)}\| \leq \frac{\|G\|^k}{1 - \|G\|} \|x^{(1)} - x^{(0)}\|$$

后验估计

先验估计

证明思路：(1)解的存在唯一性；(2)解的收敛性；(3)误差估计式。

证明： (1) 若  $I-G$  不可逆

则  $(I - G)x = 0$  有非零解  $x$ ，使得  $Gx = x$

$$\|x\| = \|Gx\| \leq \|G\| \|x\|,$$

由  $(\|G\| < 1)$ ， $\|x\| < \|x\|$ ，矛盾

所以  $I-G$  可逆，有  $(I - G)x = f$  有唯一解

$$x^* = (I - G)^{-1}f$$

$x^*$  也是  $x=Gx+f$  的唯一解。

$$(2) \quad \|x^{(k)} - x^*\| = \|(Gx^{(k-1)} + f) - (Gx^* + f)\|$$

$$= \|G(x^{(k-1)} - x^*)\|$$

$$\leq \dots \leq \|G\|^k \|x^{(0)} - x^*\| \xrightarrow{k \rightarrow \infty} 0$$

得  $x^{(k)} \rightarrow x^*$

## 直接从 $\mathbf{Ax}=\mathbf{b}$ 判断

**推论3.1** 若 $\mathbf{A}$ 按行**严格对角占优**( $|a_{ii}| > \sum_{j=1, j \neq i}^n |a_{ij}|$ ), 则解 $\mathbf{Ax}=\mathbf{b}$ 的Jacobi迭代和Gauss-Seidel迭代**均收敛**。

**谱半径 $\rho(\mathbf{G})$ :**  $\mathbf{G}$ 的**特征值的模的最大值**

**引理3.2** 设 $\mathbf{G}$ 是方阵, 则 $\mathbf{G}^k \rightarrow \mathbf{0} \Leftrightarrow \rho(\mathbf{G}) < 1$ 。

**定理3.5** 迭代 $\mathbf{x}^{(k)} = \mathbf{G}\mathbf{x}^{(k-1)} + \mathbf{f}$ 对任意初值收敛  
 $\Leftrightarrow \rho(\mathbf{G}) < 1$ 。

## 三种方法比较

方法一 (推论3.1): 从系数矩阵 $A$ 判断,  $A$ 严格对角占优, 则Jacobi迭代和Gauss-Seidel迭代收敛, 充分条件, 最方便。

方法二(定理3.4): 从迭代矩阵 $G$ 判断, 有一种范数 $\|G\| < 1$ , 充分条件。

方法三(定理3.5): 从迭代矩阵 $G$ 判断, 谱半径 $\rho(G) < 1$ , 充分必要条件, 最宽, 缺点: 求特征值, 计算困难

**例3.8** 判断Gauss-Seidel迭代求解  $A_i x=b$  的收敛性。

**P60**

解（1）系数矩阵  $A = \begin{bmatrix} 10 & -1 & -2 \\ -1 & 10 & -2 \\ -1 & -1 & 5 \end{bmatrix}$ ,  $A$  严格对角占优。

## 4. 加速迭代--SOR 迭代

在G-S迭代中

$$\begin{aligned}x_i^{(k)} &= \left( b_i - a_{i1}x_1^{(k)} - \cdots - a_{i,i-1}x_{i-1}^{(k)} - a_{i,i+1}x_{i+1}^{(k-1)} - \cdots - a_{in}x_n^{(k-1)} \right) / a_{ii} \\&= \frac{\left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k-1)} \right)}{a_{ii}}\end{aligned}$$

为了得到更好的收敛效果，可选参数 $\omega$ 作 $x_i^{(k-1)}$ 与 $x_i^{(k)}$ 两步的加权平均，于是就得到逐次超松弛迭代法，简称SOR迭代，其中 $\omega$ 称为松弛因子。

$$\text{令 } x'_i = \frac{\left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k-1)} \right)}{a_{ii}}$$

$$x_i^{(k)} = (1 - \omega)x_i^{(k-1)} + \omega x'_i$$

$$x_i^{(k)} = (1 - \omega) x_i^{(k-1)} + \frac{\omega}{a_{ii}} [b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k)} - \sum_{j=i+1}^n a_{ij} x_j^{(k-1)}]$$

收敛的必要条件  $0 < \omega < 2$ 。此时

$0 < \omega < 1$ , 称为低松弛法；让某些高斯赛德尔迭代不收敛变成收敛。

$\omega = 1$ , 称为 Gauss-Seidel 迭代；

$1 < \omega < 2$ , 称为超松弛法。

适当选取  $\omega$ , 可以加速收敛速度。

$$\mathbf{x}^{(k)} = (\mathbf{D} + \omega \mathbf{L})^{-1} [(1 - \omega) \mathbf{D} - \omega \mathbf{U}] \mathbf{x}^{(k-1)} + \omega (\mathbf{D} + \omega \mathbf{L})^{-1} \mathbf{b}$$



# Jacobi、GS 和 SOR 算法

## Jacobi 算法

$$\mathbf{x}^{(k)} = -\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})\mathbf{x}^{(k-1)} + \mathbf{D}^{-1}\mathbf{b} \quad \text{向量}$$

$$x_i^{(k)} = \left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k-1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k-1)} \right) / a_{ii} \quad \text{分量}$$

## GS 算法

$$\mathbf{x}^{(k)} = -(\mathbf{L} + \mathbf{D})^{-1} \mathbf{U}\mathbf{x}^{(k-1)} + (\mathbf{L} + \mathbf{D})^{-1} \mathbf{b} \quad \text{向量}$$

$$x_i^{(k)} = \left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k-1)} \right) / a_{ii} \quad \text{分量}$$

## SOR 算法

$$\mathbf{x}^{(k)} = (\mathbf{D} + \omega\mathbf{L})^{-1} [(1-\omega)\mathbf{D} - \omega\mathbf{U}]\mathbf{x}^{(k-1)} + \omega(\mathbf{D} + \omega\mathbf{L})^{-1} \mathbf{b}$$

$$x_i^{(k)} = (1-\omega)x_i^{(k-1)} + \omega \left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k-1)} \right) / a_{ii}$$

例：解线性方程组 
$$\begin{bmatrix} 2 & -1 & 0 \\ -1 & 3 & -1 \\ 0 & -1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 1 \\ 8 \\ -5 \end{bmatrix}$$

$$\mathbf{x}^* = \begin{bmatrix} 2 \\ 3 \\ -1 \end{bmatrix}$$

取初始向量  $\mathbf{x}^{(0)} = (0, 0, 0)$ ，迭代过程中保留小数点后4位。

解： Jacobi 迭代格式 
$$\begin{cases} x_1^{(k)} = (1 + x_2^{(k-1)})/2 \\ x_2^{(k)} = (8 + x_1^{(k-1)} + x_3^{(k-1)})/3 \\ x_3^{(k)} = (-5 + x_2^{(k-1)})/2 \end{cases}$$

令  $\mathbf{x} = (x_1, x_2, x_3)^T$  则迭代得：

$$\mathbf{x}^{(1)} = (0.5000, 2.6667, -2.5000)^T$$

$\vdots$

$$\mathbf{x}^{(21)} = (2.0000, 3.0000, -1.0000)^T$$

GS 迭代格式

$$\begin{cases} \mathbf{x}_1^{(k)} = (1 + \mathbf{x}_2^{(k-1)})/2 \\ \mathbf{x}_2^{(k)} = (8 + \mathbf{x}_1^{(k)} + \mathbf{x}_3^{(k-1)})/3 \\ \mathbf{x}_3^{(k)} = (-5 + \mathbf{x}_2^{(k)})/2 \end{cases}$$

得

$$\begin{aligned} \mathbf{x}^{(1)} &= (0.5000, 2.8333, -1.0833)^T \\ &\vdots \\ \mathbf{x}^{(9)} &= (2.0000, 3.0000, -1.0000)^T \end{aligned}$$

**SOR 迭代格式**

$$\begin{cases} \mathbf{x}_1^{(k)} = (1 - \omega)\mathbf{x}_1^{(k-1)} + \omega(1 + \mathbf{x}_2^{(k-1)})/2 \\ \mathbf{x}_2^{(k)} = (1 - \omega)\mathbf{x}_2^{(k-1)} + \omega(8 + \mathbf{x}_1^{(k)} + \mathbf{x}_3^{(k-1)})/3 \\ \mathbf{x}_3^{(k)} = (1 - \omega)\mathbf{x}_3^{(k-1)} + \omega(-5 + \mathbf{x}_2^{(k)})/2 \end{cases}$$

取  $\omega = 1.1$ ，得

$$\mathbf{x}^{(1)} = (0.5500, 3.1350, -1.0257)^T$$

$\vdots$

$$\mathbf{x}^{(7)} = (2.0000, 3.0000, -1.0000)^T$$

如何确定SOR迭代中的最优松弛因子是一件很困难的事。

# 线性方程组的迭代特点

## ---与非线性方程相比

### ➤ 复杂之处

多维问题：计算量大、理论分析需要矩阵和向量理论

### ➤ 简单之处

线性问题，理论性质好：

- ✓ 存在收敛性的充分必要条件
- ✓ 迭代收敛性仅与方程组系数矩阵有关，与右端无关
- ✓ 迭代收敛性不依赖于初始量的选取

非线性方程组的求解---Matlab

# 线性方程组的迭代法与直接法（第二章）

- 优势：对大型稀疏方程组，可利用分量形式/稀疏矩阵的方式存储，节省空间。
- 存在问题：可能不收敛

**P61-63，算法及程序**

分别写出解线性方程组

$$\begin{cases} x_1 - 5x_2 + x_3 = 16 \\ x_1 + x_2 - 4x_3 = 7 \\ -8x_1 + x_2 + x_3 = 1 \end{cases}$$

收敛的雅可比迭代格式与高斯-赛德尔迭代格式

$$\begin{cases} -8x_1 + x_2 + x_3 = 1 \\ x_1 - 5x_2 + x_3 = 16 \\ x_1 + x_2 - 4x_3 = 7 \end{cases}$$

系数矩阵  $\begin{bmatrix} -8 & 1 & 1 \\ 1 & -5 & 1 \\ 1 & 1 & -4 \end{bmatrix}$  按行严格对角占优

对应雅可比迭代格式:

$$\begin{cases} x_1^{(k+1)} = -(1 - x_2^{(k)} - x_3^{(k)})/8 \\ x_2^{(k+1)} = -(16 - x_1^{(k)} - x_3^{(k)})/5 \\ x_3^{(k+1)} = -(7 - x_1^{(k)} - x_2^{(k)})/4 \end{cases}$$

对应高斯-赛德尔格式:

$$\begin{cases} x_1^{(k+1)} = -(1 - x_2^{(k)} - x_3^{(k)})/8 \\ x_2^{(k+1)} = -(16 - x_1^{(k+1)} - x_3^{(k)})/5 \\ x_3^{(k+1)} = -(7 - x_1^{(k+1)} - x_2^{(k+1)})/4 \end{cases}$$